

Penjelasan Diagram Alur (Flowchart) Sistem Clustering

Berikut adalah narasi ilmiah formal yang menjelaskan ketiga diagram alur sistem *unsupervised clustering* menggunakan DINO ViT-S16 dan HDBSCAN, yang disusun untuk keperluan penulisan Bab III Skripsi. Anda dapat menyesuaikan penomoran Gambar (misal: Gambar 3.1) sesuai dengan format draf Anda.

1. Alur Keseluruhan Sistem (Overall Pipeline)

Gambar 3.1 mengilustrasikan arsitektur sistem yang diusulkan, yang beroperasi melalui lima tahapan pemrosesan data yang berurutan. Tahap awal melibatkan pra-pemrosesan (*preprocessing*) citra mentah untuk menstandarisasi dimensi dan menormalisasi nilai piksel citra. Selanjutnya, citra yang telah diproses dimasukkan ke dalam tahap ekstraksi fitur menggunakan arsitektur DINO ViT-S16, yang mentransformasikan representasi visual ke dalam ruang fitur berdimensi tinggi. Mengingat kompleksitas komputasional pada ruang dimensi tinggi, fitur tersebut kemudian direduksi ke dalam ruang dua dimensi menggunakan algoritma *Uniform Manifold Approximation and Projection* (UMAP). Titik-titik data hasil proyeksi tersebut kemudian menjadi masukan bagi algoritma HDBSCAN untuk melakukan pengelompokan berbasis kepadatan (*density-based clustering*). Tahap akhir dari sistem ini adalah visualisasi dan pelaporan, di mana hasil dari proses *clustering* dievaluasi secara kuantitatif dan disajikan secara grafis untuk memfasilitasi analisis lebih lanjut.

2. Detail Proses HDBSCAN (HDBSCAN Clustering Detail)

Gambar 3.2 menunjukkan proses klusterisasi secara mendetail, yang dimulai dengan menerima matriks representasi dua dimensi (`embeddings_2d.npy`) sebagai masukan untuk menginisialisasi objek HDBSCAN. Inisialisasi ini mengonfigurasi parameter utama, yaitu `min_cluster_size` , untuk mendefinisikan batas minimal anggota suatu kluster. Selain itu, sistem menetapkan metode pemilihan kluster menggunakan *Excess of Mass* (`eom`) guna mengoptimalkan stabilitas kluster yang terbentuk. Setelah proses *fit* dan *predict* dieksekusi, algoritma melakukan evaluasi kepadatan distribusi data. Area dengan kepadatan tinggi (*dense region*) akan diidentifikasi sebagai inti kluster dan diberikan label identifikasi kluster, sedangkan data yang berada pada area renggang atau terisolasi (*sparse/isolated*) akan diklasifikasikan sebagai *noise* dan diberikan label *outlier* (-1). Kinerja dari partisi data ini kemudian dievaluasi secara matematis menggunakan *Density-Based Cluster Validity* (DBCV) untuk menilai kualitas

3. Visualisasi dan Dokumentasi (Visualization & Reporting)

Gambar 3.3 memaparkan tahap akhir dari *pipeline*, yang berfokus pada interpretasi visual terhadap luaran algoritma HDBSCAN. Berdasarkan array label yang mencakup indeks klaster dan indikator anomali (-1), sistem melakukan penyaringan terstruktur untuk memisahkan data *outlier* dari anggota klaster yang valid. Data yang tergolong dalam klaster valid akan dipetakan ke dalam bentuk *scatter plot* dengan palet warna diskrit untuk merepresentasikan batasan kelompok, serta disampel untuk menyusun *comparison grid* yang menampilkan komparasi visual antar kelompok citra. Di sisi lain, data poin yang diklasifikasikan sebagai *outlier* tetap divisualisasikan dalam latar *scatter plot* menggunakan warna abu-abu netral (*grey noise*), guna memberikan konteks mengenai sebaran anomali dalam ruang laten. Keseluruhan metrik evaluasi beserta parameter operasional yang dihasilkan dari proses ini kemudian diagregasi dan didokumentasikan secara komprehensif ke dalam berkas `results/summary.md` sebagai dasar empiris untuk pelaporan penelitian.